

Отчет по вступительному заданию

Задача и подход

Объединить модель мира и VLM-скорер для управления агентом в простой среде. Агент должен пройти до зелёной целевой клетки, при этом задача задаётся только текстом

Цикл управления: модель мира RSSM фильтрует реальный кадр в латентное состояние, сэмплируются 1024 кандидатных последовательности из 15 действий, потом все они «проигрываются» в воображении (латентные прогоны RSSM), часть воображаемых кадров декодируется и оценивается CLIP относительно текста цели, после исполняется первое действие лучшего плана

Компоненты

- Данные: 500 случайных эпизодов, политика со смещением «вперёд» (21 % эпизодов достигают цели), наблюдения — полные RGB-кадры 64×64 , действия — {влево, вправо, вперёд}.
- Модель мира: RSSM в стиле PlaNet/Dreamer, 5,13 млн параметров (conv-энкодер → GRU 200 + гауссовский латент 32 → deconv-декодер, reward-голова). Loss — последовательный ELBO. Open-loop: MSE 0,6 (глубина 1) → 34 (глубина 15) при $\sim 70 - 110$ за неверную позицию агента.
- VLM-скорер: замороженный CLIP ViT-B-32; оценка кадра = $\cos(\text{цель}) - \cos(\text{базовый промпт})$. Промпты выбраны скриптованным перебором: сначала по ROC-AUC на реальных кадрах с бесплатной разметкой ($AUC = 1,0$), затем перепроверены на воображаемых кадрах в точном режиме планировщика. Перед скорингом декодированные кадры проецируются на 6-цветную палитру реальных кадров среды.
- Планировщик: random shooting, 1024 temporally-коррелированных плана (действие повторяется с $p = 0,7$ — идея «цветного шума» iCEM), максимум оценки по времени с калиброванным штрафом за задержку; $\sim 1,2$ с на шаг планирования (RTX 3080 Ti).

Результаты

Протокол: 20 эпизодов, фиксированные отложенные сиды 5000–5019 (обучение — сиды 0–499); все методы получают один и тот же список сидов (парное сравнение), оба MPC-агента идентичны во всём, кроме скорера траекторий. Базлайны — как в задании: случайный агент и тот же планировщик без VLM (целевая функция — предсказанная reward-головой награда).

Метод	Success rate	Средний return	Средние шаги
Random	5 %	0,011	59,6
Reward-MPC (без VLM)	85 %	0,660	21,6
VLM-MPC (полный конвейер)	100 %	0,763	15,8

20 held-out episodes, fixed seeds 5000–5019 (paired)




Рис. 1. Сводка оценки по трём метрикам (20 эпизодов, парные сиды).

Разрыв random → reward-MPC изолирует ценность планирования по модели мира; разрыв reward-MPC → VLM-MPC показывает, что zero-shot текстовая цель превзошла скорер, обученный на истинной награде: reward-голова иногда «залипает» на фантомной награде в латентах (защиты в латентном пространстве не существует), а путь через VLM проходит пиксельное бутылочное горлышко с проекцией на палитру, где защита возможна. Цена — вычисления: ~100x времени планирования (400 с против 4 с на всю оценку).




Рис. 2. Open-loop имажинация модели мира: ряд 1 — реальные кадры, ряд 2 — модель (с 6-й колонки видит только действия). GIF-записи поведения всех трёх агентов — в [outputs/gifs/](#).

Failure modes

- Отстающий prior: воображаемый агент растворялся за ~3 шага; вылечено KL-балансировкой.
- Антикорелированный скорер (ROC-AUC 0,019): CLIP не понимает «standing on» + баг активации QuickGELU; вылечено перебором промптов (AUC 1,0).
- Планировщик находил размытые кадры-«призраки», которые CLIP оценивал выше настоящей цели; вылечено пропагированием средних латентов и проекцией кадров на палитру среды.
- «Прокрастинация» MPC: исправлено аддитивным штрафом за время, откалиброванным между измеренными границами шума и сигнала.
- Хрупкость к чекпоинту: промпты, настроенные на одной модели, разваливались после переобучения; введена перекалибровка промптов в режиме планировщика после каждого обучения.

Отрицательные результаты (задокументированы, код оставлен): latent overshooting ухудшил open-loop MSE в ~4 раза; мультипликативный дисконт γ^t полностью стёр детекцию дальней цели (0/20).

Что дальше

- iCEM (элиты + цветной шум) вместо random shooting — меньше кандидатов, устойчивее дальний поиск.
- Более плотный сигнал VLM: подцели в промптах, регуляризация в духе VLM-RM — превратить терминальный детектор в градиент.
- DreamerV2-латенты (категориальные) и голова «эпизод продолжается» для маскировки имажинации после цели.
- Замена ручной палитры на kNN-калибровку по эмбедингам неразмеченных реальных кадров; проверка на Empty-Random, DoorKey и больших сетках.